# 目錄


概述 1.1

第一个demo 1.2

configs详解——之成员 1.3

configs详解——之field 1.4

configs详解——之requests 1.5

configs详解——之log 1.6

爬虫进阶开发——之内置方法 1.7

爬虫进阶开发——之回调函数 1.8

爬虫进阶开发——之技巧篇 1.9

- 如何实现模拟登录？ 1.9.1
- file_get_contents 设置代理抓取页面 1.9.2
- 如果内容页有分页，该如何爬取到完整数据？ 1.9.3
- 如何快速请求页面测试爬虫规则 1.9.4
- 多任务爬虫 1.9.5
- Swoole下的多任务爬虫 1.9.6
- Workerman下的多任务爬虫 1.9.7
- 如何实现爬虫集群负载？ 1.9.8

# PHP蜘蛛爬虫开发文档

《我用爬虫一天时间“偷了”知乎一百万用户，只为证明PHP是世界上最好的语言》所使用的程序框架

编写PHP网络爬虫, 需要具备以下技能:

- 爬虫采用PHP编写
- 从网页中抽取数据需要用XPath(后面会开放支持CSS选择器)
- 很多情况下都会用到正则表达式
- Chrome的开发者工具是神器, 很多AJAX请求需要用它来分析

注意：本框架只能在命令行下运行，命令行、命令行、命令行，重要的事情说三遍 ^_^

# 第一个demo

爬虫采用PHP编写, 下面以糗事百科为例, 来看一下我们的爬虫长什么样子:

```
$configs = array(
    'name' => '糗事百科',
    'domains' => array(
        'qiushibaike.com',
        'www.qiushibaike.com'
    ),
    'scan_urls' => array(
        'http://www.qiushibaike.com/'
    ),
    'content_url_regexes' => array(
        "http://www.qiushibaike.com/article/\d+"
    ),
    'list_url_regexes' => array(
        "http://www.qiushibaike.com/8hr/page/\d+\?s=\d+"
    ),
    'fields' => array(
        array(
            // 抽取内容页的文章内容
            'name' => "article_content",
            'selector' => "//*[@id='single-next-link']",
            'required' => true
        ),
        array(
            // 抽取内容页的文章作者
            'name' => "article_author",
            'selector' => "//div[contains(@class,'author')]//h2"
,
            'required' => true
        ),
    ),
);
$spider = new phpspider($configs);
$spider->start();
```

爬虫的整体框架就是这样, 首先定义了一个$configs数组, 里面设置了待爬网站的一些信息, 然后通过调用 `$spider = new phpspider($configs);` 和 `$spider->start();` 来配置并启动爬虫.

## 运行界面如下:

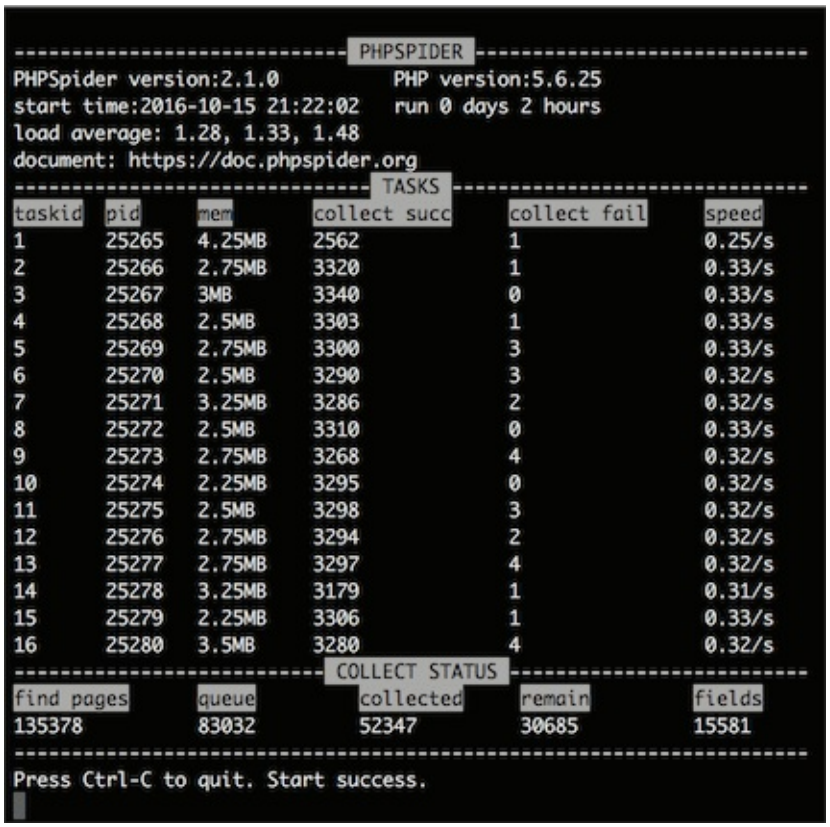


$configs对象如何定义, 后面会作详细介绍.^_^

# configs详解——之成员

爬虫的整体框架是这样：首先定义了一个$configs数组, 里面设置了待爬网站的一些信息, 然后通过调用 `$spider = new phpspider($configs);` 和 `$spider->start();` 来配置并启动爬虫.

$configs数组中可以定义下面这些元素

## name

> 定义当前爬虫名称

**String**类型 可选设置

举个栗子:

```
'name' => '糗事百科'
```

## log_show

> 是否显示日志

布尔类型 可选设置

**log_show**默认值为**false**，即显示爬取面板

举个栗子:

```
'log_show' => true
```

**log_show**为**false**时

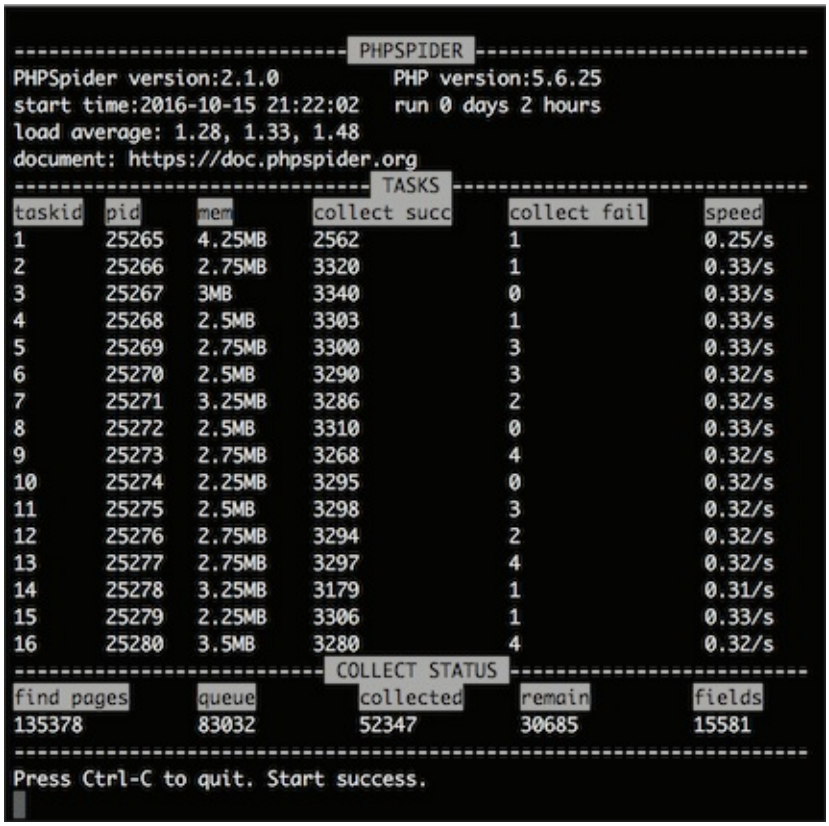


**log_show**为**true**时

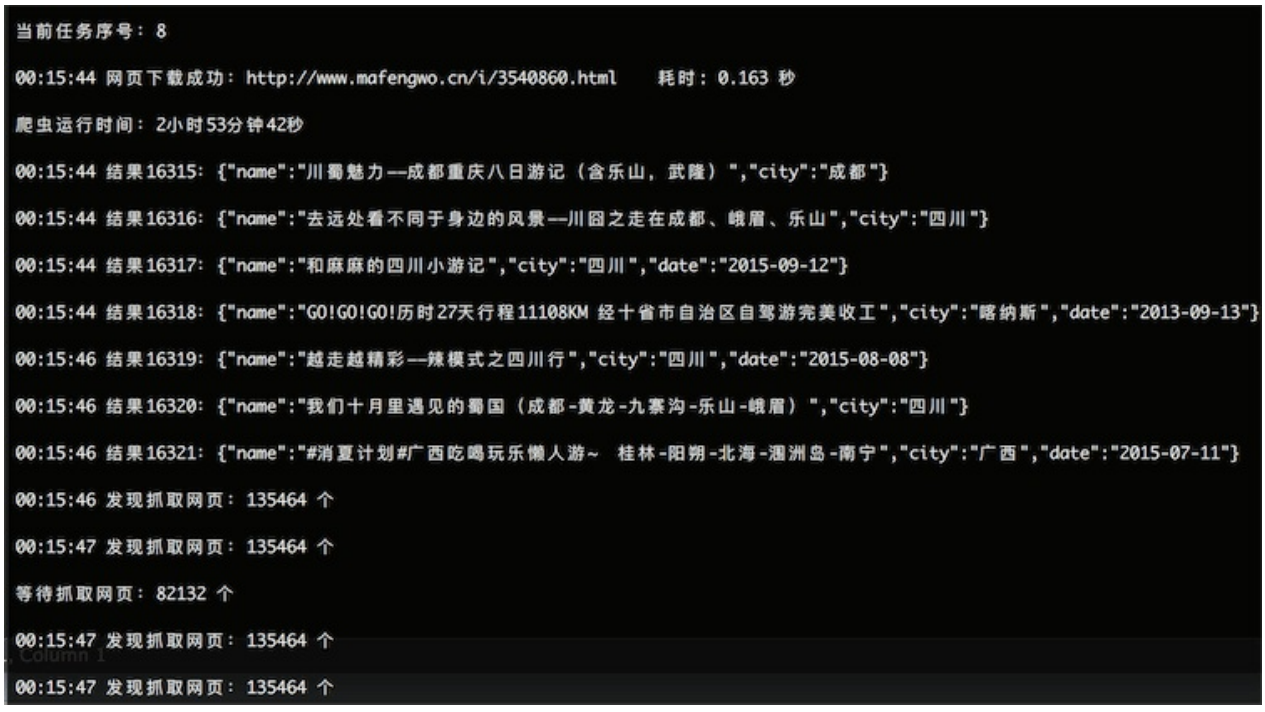


注意：设置**log_show**为**false**时，可以通过查看日志来观察程序

```
tail -f data/phpspider.log
```

## save_running_state

> 保存爬虫运行状态
> 设置为true则程序会调用redis作为任务数据存储
> 需要配合redis来保存采集任务数据，供程序下次执行使用

布尔类型 可选设置

**save_running_state**默认值为**false**，即不保存爬虫运行状态

举个栗子:

```
'save_running_state' => true
```

## input_encoding

> 输入编码
> 明确指定输入的页面编码格式(UTF-8,GB2312,.....)，防止出现乱码,如果设置null则自动识别

**String**类型 可选设置

**input_encoding**默认值为**null**，即程序自动识别页面编码

举个栗子:

```
'input_encoding' => 'GB2312'
```

## tasknum

> 同时工作的爬虫任务数
> 需要配合redis保存采集任务数据，供进程间共享使用
> 需要配合自带的worker类、Swoole或者Workerman的多进程使用

整型 可选设置

**tasknum**默认值为**1**，即单进程任务爬取

举个栗子:

开启5个进程爬取网页

```
'tasknum' => 5
```

多任务爬虫

Swoole下的多任务爬虫

Workerman下的多任务爬虫

注意: 保存爬虫运行状态 和 多任务 都需要 **redis** 来保存采集任务数据，修改 **config/inc_config.php** 文件中的 **redis**配置

```
$GLOBALS['config']['redis'] = array(
    'host'      => '127.0.0.1',
    'port'      => 6379,
    'pass'      => '',
    'prefix'    => 'phpspider',
    'timeout'   => 30,
);
```

## domains

> 定义爬虫爬取哪些域名下的网页, 非域名下的url会被忽略以提高爬取速度

数组类型 不能为空

举个栗子:

```
'domains' => array(
    'qiushibaike.com',
    'www.qiushibaike.com'
)
```

## scan_urls

> 定义爬虫的入口链接, 爬虫从这些链接开始爬取,同时这些链接也是监控爬虫所要监控的链接

数组类型 不能为空

举个栗子:

```
'scan_urls' => array(
    'http://www.qiushibaike.com/'
)
```

## content_url_regexes

> 定义内容页url的规则
> 内容页是指包含要爬取内容的网页 比
> 如 `http://www.qiushibaike.com/article/115878724` 就是糗事百科的一个内容页

数组类型 正则表达式 最好填写以提高爬取效率

举个栗子:

```
'content_url_regexes' => array(
    "http://www.qiushibaike.com/article/\d+",
)
```

## list_url_regexes

> 定义列表页url的规则
> 对于有列表页的网站,使用此配置可以大幅提高爬虫的爬取速率
> 列表页是指包含内容页列表的网页 比
> 如 `http://www.qiushibaike.com/8hr/page/2/?s=4867046` 就是糗事百科的一个列表页

数组类型 正则表达式

举个栗子:

```
'list_url_regexes' => array(
    "http://www.qiushibaike.com/8hr/page/\d+\?s=\d+"
)
```

## fields

> 定义内容页的抽取规则
> 规则由一个个 `field` 组成, 一个 `field` 代表一个数据抽取项

数组类型 不能为空

举个栗子:

```
'fields' => array(
    array(
        'name' => "content",
        'selector' => "//*[@id='single-next-link']",
        'required' => true,
    ),
    array(
        'name' => "author",
        'selector' => "//div[contains(@class,'author')]//h2",
    )
)
```

上面的例子从网页中抽取内容和作者, 抽取规则是针对糗事百科的内容页写的

> `field` 在configs详解——之field中作详细介绍。

## proxy

> 代理服务器
> 如果爬取的网站根据IP做了反爬虫, 可以设置此项

数组类型 可选设置

栗子1:
普通代理

```
'proxy' => 'http://host:port'
```

栗子2:
验证代理

```
'proxy' => 'http://user:pass@host:port'
```

注意：如果对方根据**IP**做了反爬虫技术，你可能需要到 阿布云代理 申请代理通道或者 第三方免费代理**IP**，然后在这里填写代理信息

## interval

> 爬虫爬取每个网页的时间间隔
> 单位：毫秒

整型 可选设置

举个栗子:
设置爬取时间间隔为1秒

```
'interval' => 1000
```

## timeout

> 爬虫爬取每个网页的超时时间
> 单位：秒

整型 可选设置

**timeout**默认值为**5**秒

举个栗子:

```
'timeout' => 5
```

## max_try

> 爬虫爬取每个网页失败后尝试次数
> 网络不好可能导致爬虫在超时时间内抓取失败, 可以设置此项允许爬虫重复爬取

整型 可选设置

**max_try**默认值为**0**，即不重复爬取

举个栗子:

```
'max_try' => 5 // 重复爬取5次
```

## max_depth

> 爬虫爬取网页深度，超过深度的页面不再采集
> 对于抓取最新内容的增量更新，抓取好友的好友的好友这类型特别有用

整型 可选设置

`max_depth` 默认值为**0**，即不限制

举个栗子: 采集知乎好友时只采集到5级深度

```
'max_depth' => 5
```

## max_fields

> 爬虫爬取内容网页最大条数
> 抓取到一定的字段后退出

整型 可选设置

`max_fields` 默认值为**0**，即不限制

举个栗子:

```
'max_fields' => 100
```

## user_agent

> 爬虫爬取网页所使用的浏览器类型
> `phpspider::AGENT_ANDROID`
> `phpspider::AGENT_IOS`
> `phpspider::AGENT_PC`
> `phpspider::AGENT_MOBILE`

枚举类型 可选设置

栗子1:
使用内置的枚举类型

**`phpspider::AGENT_ANDROID`**，表示爬虫爬取网页时，使用安卓手机浏览器
**`phpspider::AGENT_IOS`**，表示爬虫爬取网页时，使用苹果手机浏览器
**`phpspider::AGENT_PC`**，表示爬虫爬取网页时，使用**PC**浏览器
**`phpspider::AGENT_MOBILE`**，表示爬虫爬取网页时，使用移动设备浏览器

```
'user_agent' => phpspider::AGENT_ANDROID
```

栗子2:
使用自定义类型

```
'user_agent' => "Mozilla/5.0"
```

## `export`

> 爬虫爬取数据导出
>
> > export_type：导出类型 csv、sql、db
> > export_file：导出 csv、sql 文件地址
> > export_table：导出db、sql数据表

注意导出到数据库的表和字段要和上面的**fields**对应

数组类型 可选设置

栗子1:
导出CSV结构数据到文件

```
'export' => array(
    'type' => 'csv',
    'file' => PATH_DATA.'/qiushibaike.csv', // data目录下
)
```

栗子2:
导出SQL语句到文件

```
'export' => array(
    'type'  => 'sql',
    'file'  => PATH_DATA.'/qiushibaike.sql',
    'table' => '数据表',
)
```

栗子3:
导出数据到Mysql

```
'export' => array(
    'type' => 'db',
    'table' => '数据表',  // 如果数据表没有数据新增请检查表结构和字段名是否匹配
)
```

注意: 导出到 **Mysql** 需要修改 **config/inc_config.php** 文件中的 **mysql**配置

```
$GLOBALS['config']['db'] = array(
    'host'  => '127.0.0.1',
    'port'  => 3306,
    'user'  => 'root',
    'pass'  => 'root',
    'name'  => 'demo',
);
```

# configs详解——之field

`field` 定义一个抽取项, 一个 `field` 可以定义下面这些东西

## name

> 给此项数据起个变量名
> 变量名中不能包含.
> 如果抓取到的数据想要以文章或者问答的形式发布到网站(WeCenter, WordPress, Discuz!等), field的命名请参考两个完整demo中的命名, 否则无法发布成功

**String**类型 不能为空

举个栗子:

给 `field` 起了个名字叫 `content`

```
array(
    'name' => "content",
    'selector' => "//*[@id='single-next-link']"
)
```

## selector

> 定义抽取规则, 默认使用xpath
> 如果使用其他类型的, 需要指定selector_type

**String**类型 不能为空

举个栗子:
使用xpath来抽取糗事百科的笑话内容，selector的值就是内容的xpath

```
array(
    'name' => "content",
    'selector' => "//*[@id='single-next-link']"
)
```

## selector_type

抽取规则的类型

> 目前可用xpath, jsonpath, regex
> 默认 `xpath`

枚举类型

栗子1:
selector默认使用xpath

```
array(
    'name' => "content",
    'selector' => "//*[@id='single-next-link']" // xpath抽取规则
)
```

栗子2:
使用正则表达式来抽取数据

```
array(
    'name' => "content",
    'selector_type' => 'regex',
    'selector' => '#<div\sclass="content">([^/]+)</div>#i' // re
gex抽取规则
)
```

## required

> 定义该 `field` 的值是否必须, 默认false
> 赋值为true的话, 如果该 `field` 没有抽取到内容, 该field对应的整条数据都将被丢弃

布尔类型

举个栗子:

```
array(
    'name' => "content",
    'selector' => "//*[@id='single-next-link']",
    'required' => true
)
```

## repeated

> 定义该 `field` 抽取到的内容是否是有多项,默认 `false`
> 赋值为true的话,无论该 `field` 是否眞的是有多项,抽取到的结果都是数组结构

布尔类型

举个栗子:
爬取的网页中包含多条评论，所以抽取评论的时候要将repeated赋值为true

```
array(
    'name' => "comments",
    'selector' => "//*[@id='zh-single-question-page']//a[contains(@class,'zm-item-tag')]",
    'repeated' => true
)
```

## children

> 为此 `field` 定义子项
> 子项的定义仍然是一个 `fields` 数组
> 没错,这是一个树形结构

数组类型

举个栗子:
抓取糗事百科的评论，每个评论爬取了内容，点赞数

```
array(
    'name' => "article_comments",
    'selector' => "//div[contains(@class,'comments-wrap')]",
    'children' => array(
        array(
            'name' => "replay",
            'selector' => "//div[contains(@class,'replay')]",
            'repeated' => true,
        ),
        array(
            'name' => "report",
            'selector' => "//div[contains(@class,'report')]",
            'repeated' => true,
        )
    )
)
```

## source_type

该field的数据源, 默认从当前的网页中抽取数据
选择 `attached_url` 可以发起一个新的请求, 然后从请求返回的数据中抽取
选择 `url_context` 可以从当前网页的url附加数据（点此查看“url附加数据”实例解析）中抽取

枚举类型

## attached_url

当source_type设置为 `attached_url` 时, 定义新请求的url

**String**类型

举个栗子:
当爬取的网页中某些内容需要异步加载请求时，就需要使用attached_url，比如，抓取知乎回答中的评论部分，就是通过AJAX异步请求的数据

```
array(
    'name' => "comment_id",
    'selector' => "//div/@data-aid",
),
array(
    'name' => "comments",
    'source_type' => 'attached_url',
    // "comments"是从发送"attached_url"这个异步请求返回的数据中抽取的
    // "attachedUrl"支持引用上下文中的抓取到的"field", 这里就引用了上面
抓取的"comment_id"
    'attached_url' => "https://www.zhihu.com/r/answers/{comment_
id}/comments",
    'selector_type' => 'jsonpath'
    'selector' => "$.data",
    'repeated => true,
    'children' => array(
        ...
    )
}
```

# configs详解——之requests

`requests` 表示当前正在爬取的网站的对象，下面介绍了可以调用的函数

## `requests::set_timeout($timeout)`

一般在 `on_start` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 设置请求超时时间

> @param $timeout 需添加的timeout

默认值为**5**，即**5**秒超时

举个栗子:

```
$spider->on_start = function($phpspider)
{
    requests::set_timeout(10);
};
```

## `requests::set_useragent($useragent)`

一般在 `on_start` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 设置浏览器useragent

> @param $useragent 需添加的useragent

默认使用**useragent: phpspider-requests/2.10.0**

点击查看“常见浏览器useragent大全”

举个栗子:

```
$spider->on_start = function($phpspider)
{
    requests::set_useragent("Mozilla/4.0 (compatible; MSIE 6.0;
) Opera/UCWEB7.0.2.37/28/");
};
```

## requests::set_useragents($useragents)

一般在 `on_start` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 设置浏览器useragent

> @param $useragents 需添加的随机useragent

传递了**useragent**数组后，爬虫请求的时候就会随机取一个**useragent**访问对方网站，让对方网站对**useragent**的反爬虫限制失效

点击查看“常见浏览器useragent大全”

举个栗子:

```
$spider->on_start = function($phpspider)
{
    requests::set_useragents(array(
        "Mozilla/4.0 (compatible; MSIE 6.0; ) Opera/UCWEB7.0.2.3
7/28/",
        "Opera/9.80 (Android 3.2.1; Linux; Opera Tablet/ADR-1109
081720; U; ja) Presto/2.8.149 Version/11.10",
        "Mozilla/5.0 (Android; Linux armv7l; rv:9.0) Gecko/20111
216 Firefox/9.0 Fennec/9.0"
    ));
};
```

## requests::add_header($key, $value)

一般在 `on_start` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 用来添加一些HTTP请求的Header

> @param $key Header的key, 如User-Agent,Referer等
> @param $value Header的值

举个栗子:
Referer是HTTP请求Header的一个属性， `http://www.9game.cn/kc/` 是Referer的值

```
$spider->on_start = function($phpspider)
{
    requests::add_header("Referer", "http://www.9game.cn/kc/");
};
```

## requests::add_cookie($key, $value, $domain='')

一般在 on_start 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 用来添加一些HTTP请求的Cookie

> @param $key Cookie的key
> @param $value Cookie的值 @param $domain 默认放到全局Cookie，设置域名后则放到相应域名下

举个栗子:
cookie是由键-值对组成的，BAIDUID是cookie的key，FEE96299191CB0F11954F3A0060FB470:FG=1则是cookie的值

```
$spider->on_start = function($phpspider)
{
    requests::add_cookie("BAIDUID", "FEE96299191CB0F11954F3A0060
FB470:FG=1");
    // 把Cookie设置到 www.phpspider.org 域名下
    requests::add_cookie("NAME", "phpspider", "www.phpspider.org
");
};
```

## requests::get_cookie($name, $domain = '')

一般在 on_start 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 用来得到某个域名所附带的某个Cookie

> @param $name Cookie的名称
> @param $domain configs的domains成员中的元素

举个栗子:
得到 `s.weibo.com` 域名所附带的 `Cookie` , 并将 `Cookie` 添加到 `weibo.com` 的域名中

```
$configs = array(
    'domains' => array(
        's.weibo.com',
        'weibo.com'
    )
    // configs的其他成员
    ...
);

$spider->on_start = function($phpspider)
{
    $cookie = requests::get_cookie("SUB", "s.weibo.com");
    // 把Cookie设置到 weibo.com 域名下
    requests::add_cookie("SUB", $cookie, "weibo.com");
};
```

## requests::add_cookies($cookies, $domain='')

一般在 `on_start` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 用来添加一些HTTP请求的Cookie

> @param $cookies 多个Cookie组成的字符串
> @param $domain 默认放到全局Cookie，设置域名后则放到相应域名下

举个栗子:
cookies是多个cookie的键-值对组成的字符串，用;分隔。BAIDUID和BIDUPSID是cookie的key，FEE96299191CB0F11954F3A0060FB470:FG=1和FEE96299191CB0F11954F3A0060FB470是cookie的值，键-值对用=相连

```
$spider->on_start = function($phpspider)
{
    requests::add_cookies("BAIDUID=FEE96299191CB0F11954F3A0060FB
470:FG=1; BIDUPSID=FEE96299191CB0F11954F3A0060FB470;");
    // 把Cookie设置到 www.phpspider.org 域名下
    requests::add_cookies("NAME", "www.phpspider.org");
};
```

## requests::get_cookies($domain = '')

一般在 `on_start` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 用来得到某个域名所附带的所有Cookie

> @param $domain configs的domains成员中的元素
> @return array 返回的是所有Cookie的数组

举个栗子:
得到 `s.weibo.com` 域名所附带的 `Cookie` , 并将 `Cookie` 添加到 `weibo.com` 的域名中

```
$configs = array(
    'domains' => array(
        's.weibo.com',
        'weibo.com'
    )
    // configs的其他成员
    ...
);

$spider->on_start = function($phpspider)
{
    $cookies = requests::get_cookies("s.weibo.com");
    // 返回的是数组，可以输出看看所有的Cookie内容
    print_r($cookies);
    // 数组转化成String
    $cookies = implode(";", $cookies);
    // 把Cookie设置到 weibo.com 域名下
    requests::add_cookies($cookies, "weibo.com");

};
```

## requests::get($url, $params)

可以在任何地方调用, 用来获取某个网页

> @param $url 请求URL
> @param $params 请求参数

举个栗子:
获取 Github 的公共时间线

```
$json = requests::get("https://github.com/timeline.json");
$data = json_decode($json, true);
print_r($data);
```

## requests::post($url, $params)

可以在任何地方调用, 用来获取某个网页

> @param $url 请求URL
> @param $params 请求参数

举个栗子:
用户登录

```
$params = array(
    'username' => 'test888',
    'password' => '123456',
);
$html = requests::post("http://www.domain.com", $params);
```

## requests::put($url, $params)

可以在任何地方调用, 用来获取某个网页

> @param $url 请求URL
> @param $params 请求参数

举个栗子:
添加用户 test888

```
$params="{username:\"test888\",username:\"123456\"}";
$html = requests::put("http://www.domain.com", $params);
```

## requests::delete($url, $params)

可以在任何地方调用, 用来获取某个网页

> @param $url 请求URL
> @param $params 请求参数

举个栗子:
删除用户 test888

```
$params="{username:\"test888\"}";
$html = requests::delete("http://www.domain.com", $params);
```

## curl

curl -X PUT http://www.domain.com/demo.php -d "id=1" -d "title=a"

# configs详解——之log

## log

`log` 对象提供不同级别的日志打印

### `log::info($msg)`

打印普通日志

举个栗子:

```
log::info("成功处理一个页面");
```

### `log::debug($msg)`

打印出错级别日志,调试时使用

举个栗子:

```
log::debug("正在提取文章标题数据");
```

### `log::warn($msg)`

打印警告情况的日志

举个栗子:

```
log::warn("XX文件解析失败");
```

### `log.error($msg)`

打印错误情况的日志

举个栗子:

```
log::error("XPath错误");
```

# 爬虫进阶开发——之内置方法

本节介绍爬虫的内置方法

## add_url($url, $options = array())

一般在 on_scan_page 和 on_list_page 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 用来往待爬队列中添加url

> @param $url 待添加的url
> @param $options 成员包括method, headers, params, context_data, reserve 和 proxy, 如下所示:
>
> > @param $options['method'] 默认为"get"请求, 也支持"post"请求
> > @param $options['headers'] 此url的Headers, 可以为空
> > @param $options['params'] 发送请求时需添加的参数, 可以为空
> > @param $options['context_data'] 此url附加的数据, 比如内容页需要列表页一些数据, 可以为空
> > @param $options['proxy'] 访问此url时使用的代理服务器，不使用请留空

栗子1:

```
$spider->on_scan_page = function($page, $content, $phpspider)
{
    $regex = "#http://pic.qiushibaike.com/system/pictures/\d+#";
    $urls = array();
    preg_match_all($regex, $content, $out);
    $urls = empty($out[0]) ? array() : $out[0];
    if (!empty($urls)) {
        foreach ($urls as $url)
        {
            $phpspider->add_url($url);
        }
    }
    ...
    return false;
};
```

## add_scan_url($url, $options = array())

一般在 `on_start` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 用来往待爬队列中添加scan_url

> @param $url 待添加的scan_url
> @param $options 成员包括method, headers, params, context_data, reserve 和 proxy, 如下所示:
>
> > @param $options['method'] 默认为"get"请求, 也支持"post"请求
> > @param $options['headers'] 此url的Headers, 可以为空
> > @param $options['params'] 发送请求时需添加的参数, 可以为空
> > @param $options['context_data'] 此url附加的数据, 比如内容页需要列表页一些数据, 可以为空
> > @param $options['proxy'] 访问此url时使用的代理服务器，不使用请留空

举个栗子:

```
$spider->on_start = function($page, $content, $phpspider)
{
    for ($i = 0; $i < 10; $i++)
    {
        $phpspider->add_scan_url("http://www.qiushibaike.com/page.php?page=".$i);
    }
};
```

栗子2:

```
$spider->on_list_page = function($page, $content, $phpspider)
{
    ...
    $next_url = str_replace($page['url'], "page=".$current_page_
num, "page=".$page_num);
    $options = array(
        'method' => 'post',
        'params' => array(
            'page' => $page_num,
            'size' => 18
        )
    );
    $phpspider->add_url($next_url, $options);
    return false;
};
```

## request_url($url, $options = array())

一般在 `on_start` , `on_download_page` , `on_scan_page` 和 `on_list_page` 回调函数（在爬虫进阶开发——之回调函数中会详细描述）中调用, 下载网页, 得到网页内容

> @param $url 待添加的url
> @param $options 成员包括method, headers, params, context_data, reserve 和 proxy, 如下所示:
>
> > @param $options['method'] 默认为"get"请求, 也支持"post"请求
> > @param $options['headers'] 此url的Headers, 可以为空
> > @param $options['params'] 发送请求时需添加的参数, 可以为空
> > @param $options['context_data'] 此url附加的数据, 比如内容页需要列表页一些数据, 可以为空
> > @param $options['proxy'] 访问此url时使用的代理服务器，不使用请留空

举个栗子:

```
$spider->on_download_page = function($page, $phpspider)
{
    $url = "https://checkcoverage.apple.com/cn/zh/?sn=FK1QPNCEGR
YD";
    $options = array(
        'method' => 'post',
        'params' => array(
            'sno' => 'FK1QPNCEGRYD',
            'CSRFToken' => $result[1]
        )
    );
    // 通过发送带参数的post请求，下载网页，并将网页内容赋值给result
    $request = $phpspider->request_url($url, $options);
    ...
    return $page;
};
```

# 爬虫进阶开发——之回调函数

回调函数是在爬虫爬取并处理网页的过程中设置的一些系统钩子,通过这些钩子可以完成一些特殊的处理逻辑.

下图是PHP蜘蛛爬虫爬取并处理网页的流程图，矩形方框中标识了爬虫运行过程中所使用的重要回调函数：

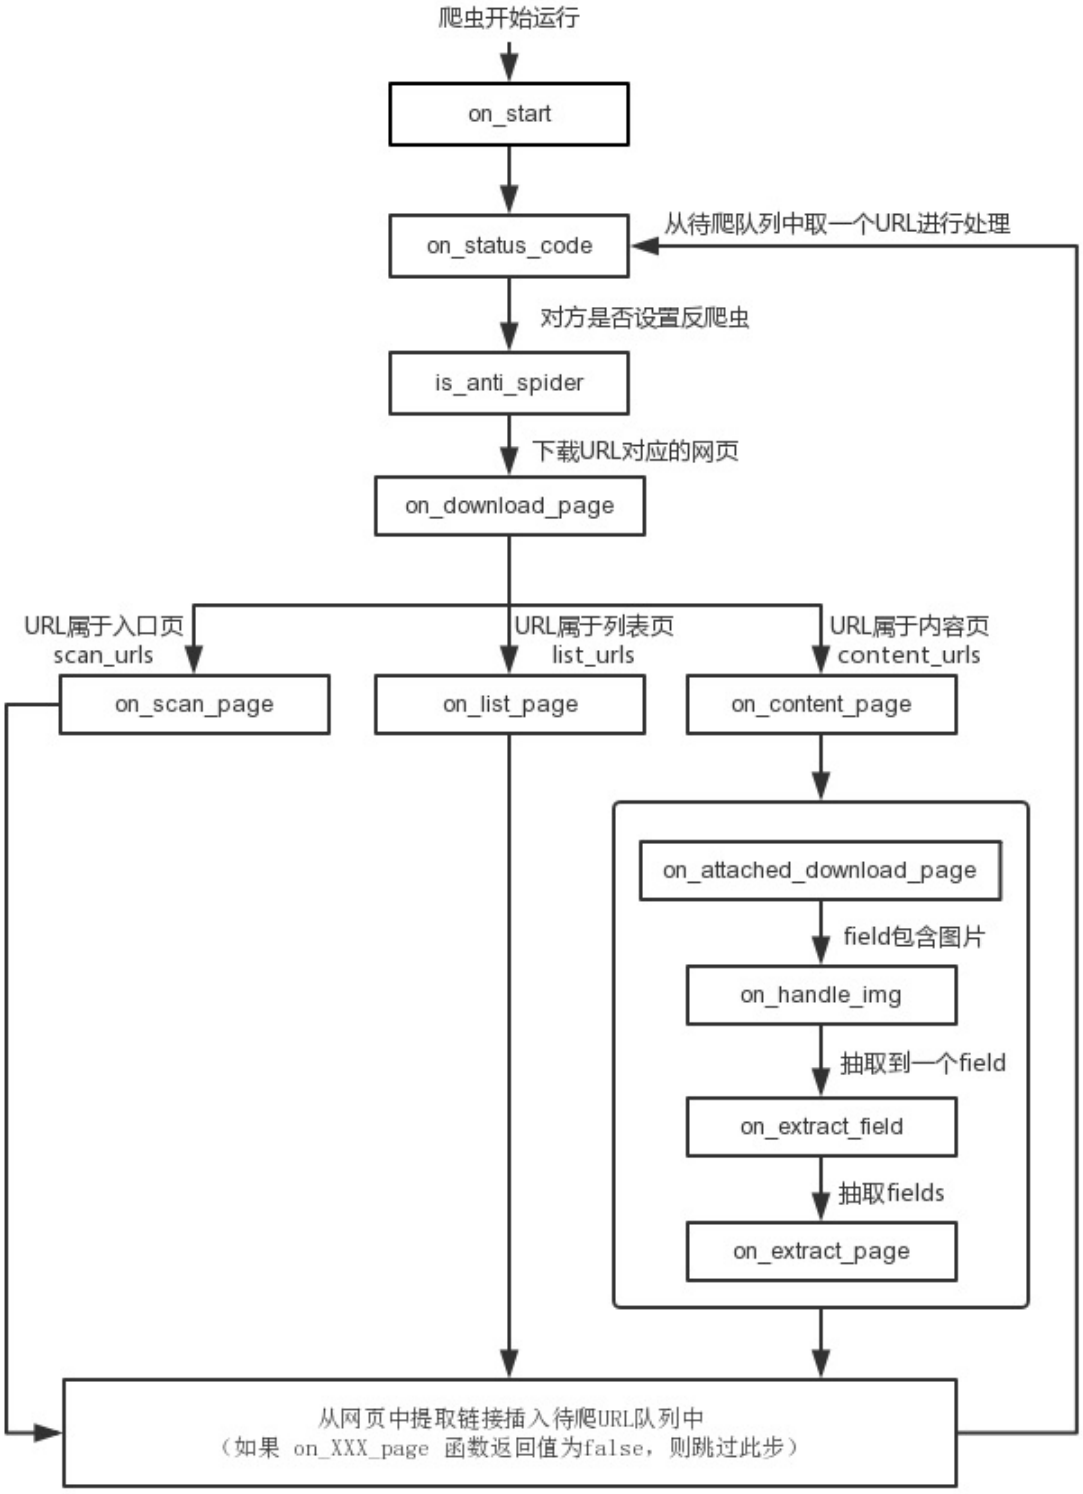


## `on_start($phpspider)`

爬虫初始化时调用,用来指定一些爬取前的操作

> @param $phpspider 爬虫对象

在函数中可以调用 `requests::add_header($key,$value)`，`requests::add_cookie($key,$value)`，`requests::add_cookies($cookies)` 等

举个栗子:

在爬虫开始爬取之前给所有待爬网页添加一个Header

```
$spider->on_start = function($phpspider)
{
    requests::add_header("Referer", "http://buluo.qq.com/p/index
.html");
};
```

## `on_status_code($status_code, $url, $content, $phpspider)`

判断当前网页是否被反爬虫了,需要开发者实现

> @param $status_code 当前网页的请求返回的HTTP状态码
> @param $url 当前网页URL
> @param $content 当前网页内容
> @param $phpspider 爬虫对象
> @return $content 返回处理后的网页内容，不处理当前页面请返回false

举个栗子:

```
$spider->on_status_code = function($status_code, $url, $content,
 $phpspider)
{
    // 如果状态码为429，说明对方网站设置了不让同一个客户端同时请求太多次
    if ($status_code == '429')
    {
        // 将url插入待爬的队列中,等待再次爬取
        $phpspider->add_url($url);
        // 当前页先不处理了
        return false;
    }
    // 不拦截的状态码这里记得要返回，否则后面内容就都空了
    return $content;
};
```

## is_anti_spider($url, $content, $phpspider)

判断当前网页是否被反爬虫了,需要开发者实现

> @param $url 当前网页的url
> @param $content 当前网页内容
> @param $phpspider 爬虫对象
> @return 如果被反爬虫了, 返回true, 否则返回false

举个栗子:

```
$spider->is_anti_spider = function($url, $content, $phpspider)
{
    // $content中包含"404页面不存在"字符串
    if (strpos($content, "404页面不存在") !== false)
    {
        // 如果使用了代理IP，IP切换需要时间，这里可以添加到队列等下次换了IP再抓取
        // $phpspider->add_url($url);
        return true; // 告诉框架网页被反爬虫了，不要继续处理它
    }
    // 当前页面没有被反爬虫，可以继续处理
    return false;
};
```

## on_download_page($page, $phpspider)

在一个网页下载完成之后调用.主要用来对下载的网页进行处理.

> @param $page 当前下载的网页页面的对象
> @param $phpspider 爬虫对象
> @return 返回处理后的网页内容
>
> > @param $page['url'] 当前网页的URL
> > @param $page['raw'] 当前网页的内容
> > @param $page['request'] 当前网页的请求对象

举个栗子:
比如下载了某个网页，希望向网页的body中添加html标签，处理过程如下：

```
$spider->on_download_page = function($page, $phpspider)
{
    $page_html = "<div id=\"comment-pages\"><span>5</span></div>
";
    $index = strpos($page['row'], "</body>");
    $page['raw'] = substr($page['raw'], 0, $index) . $page_html
. substr($page['raw'], $index);
    return $page;
};
```

## on_attached_download_page($content, $phpspider)

在一个网页下载完成之后调用.主要用来对下载的网页进行处理.

> @param $content 当前下载的网页页面的内容
> @param $phpspider 爬虫对象
> @return 返回处理后的网页内容

举个栗子:
比如下载的网页需去掉前后两边的中括号，并将处理后的数据返回，处理过程如下：

```
$spider->on_attached_download_page = function($content, $phpspid
er)
{
    $content = trim($content);
    $content = ltrim($content, "[");
    $content = rtrim($content, "]");
    $content = json_decode($content, true);
    return $content;
};
```

## on_scan_page($page, $content, $phpspider)

在爬取到入口**url**的内容之后,添加新的**url**到待爬队列之前调用.主要用来发现新的待爬**url**,并且能给新发现的**url**附加数据（点此查看**“url**附加数据”实例解析）.

> @param $page 当前正在爬取的网页页面的对象
> @param $content 当前网页内容
> @param $phpspider 当前爬虫对象
> @return 返回false表示不需要再从此网页中发现待爬url
>
> > @param $page['url'] 当前网页的URL
> > @param $page['raw'] 当前网页的内容
> > @param $page['request'] 当前网页的请求对象

此函数中通过调用$phpspider->add_url($url, $options)函数来添加新的url到待爬队列。

栗子1:
实现这个回调函数并返回false，表示爬虫在处理这个scan_url的时候，不会从中提取待爬url

```
$spider->on_scan_page = function($page, $content, $phpspider)
{
    return false;
};
```

栗子2:
生成一个新的url添加到待爬队列中，并通知爬虫不再从当前网页中发现待爬url

```
$spider->on_scan_page = function($page, $content, $phpspider)
{
    $array = json_decode($page['raw'], true);
    foreach ($array as $v)
    {
        $lastid = $v['id'];
        // 生成一个新的url
        $url = $page['url'] . $lastid;
        // 将新的url插入待爬的队列中
        $phpspider->add_url($url);
    }
    // 通知爬虫不再从当前网页中发现待爬url
    return false;
};
```

## on_list_page($page, $content, $phpspider)

在爬取到入口**url**的内容之后, 添加新的**url**到待爬队列之前调用. 主要用来发现新的待爬**url**, 并且能给新发现的**url**附加数据（点此查看**“url**附加数据”实例解析）.

> @param $page 当前正在爬取的网页页面的对象 @param $content 当前网页内容
> @param $phpspider 当前爬虫对象
> @return 返回false表示不需要再从此网页中发现待爬url
>
> > @param $page['url'] 当前网页的URL
> > @param $page['raw'] 当前网页的内容
> > @param $page['request'] 当前网页的请求对象

此函数中通过调用$phpspider->add_url($url, $options)函数来添加新的url到待爬队列。

栗子1:
实现这个回调函数并返回false，表示爬虫在处理这个scan_url的时候，不会从中提取待爬url

```
$spider->on_list_page = function($page, $content, $phpspider)
{
    return false;
};
```

栗子2:
生成一个新的url添加到待爬队列中，并通知爬虫不再从当前网页中发现待爬url

```
$spider->on_list_page = function($page, $content, $phpspider)
{
    $array = json_decode($page['raw'], true);
    foreach ($array as $v)
    {
        $lastid = $v['id'];
        // 生成一个新的url
        $url = $page['url'] . $lastid;
        // 将新的url插入待爬的队列中
        $phpspider->add_url($url);
    }
    // 通知爬虫不再从当前网页中发现待爬url
    return false;
};
```

## on_content_page($page, $content, $phpspider)

在爬取到入口**url**的内容之后, 添加新的**url**到待爬队列之前调用. 主要用来发现新的待爬**url**, 并且能给新发现的**url**附加数据（点此查看**“url**附加数据”实例解析）.

> @param $page 当前正在爬取的网页页面的对象
> @param $content 当前网页内容
> @param $phpspider 当前爬虫对象
> @return 返回false表示不需要再从此网页中发现待爬url
>
> > @param $page['url'] 当前网页的URL
> > @param $page['raw'] 当前网页的内容
> > @param $page['request'] 当前网页的请求对象

此函数中通过调用$phpspider->add_url($url, $options)函数来添加新的url到待爬队列。

栗子1:
实现这个回调函数并返回false，表示爬虫在处理这个scan_url的时候，不会从中提取待爬url

```
$spider->on_content_page = function($page, $content, $phpspider)

{
    return false;
};
```

栗子2:
生成一个新的url添加到待爬队列中，并通知爬虫不再从当前网页中发现待爬url

```
$spider->on_content_page = function($page, $content, $phpspider)

{
    $array = json_decode($page['raw'], true);
    foreach ($array as $v)
    {
        $lastid = $v['id'];
        // 生成一个新的url
        $url = $page['url'] . $lastid;
        // 将新的url插入待爬的队列中
        $phpspider->add_url($url);
    }
    // 通知爬虫不再从当前网页中发现待爬url
    return false;
};
```

## on_handle_img($fieldname, $img)

在抽取到**field**内容之后调用, 对其中包含的**img**标签进行回调处理

> @param $fieldname 当前field的name. 注意: 子field的name会带着父field的name, 通过.连接.
> @param $img 整个img标签的内容
> @return 返回处理后的img标签的内容

很多网站对图片作了延迟加载, 这时候就需要在这个函数里面来处理

举个栗子:
汽车之家论坛帖子的图片大部分是延迟加载的，默认会使用 `http://x.autoimg.cn/club/lazyload.png` 图片url，我们需要找到真实的图片url并替换，具体实现如下：

```
$spider->on_handle_img = function($fieldname, $img)
{
    $regex = '/src="(https?:\/\/.*?)"/i';
    preg_match($regex, $img, $rs);
    if (!$rs)
    {
        return $img;
    }
    $url = $rs[1];
    if ($url == "http://x.autoimg.cn/club/lazyload.png")
    {
        $regex2 = '/src9="(https?:\/\/.*?)"/i';
        preg_match($regex, $img, $rs);
        // 替换成真是图片url
        if (!$rs)
        {
            $new_url = $rs[1];
            $img = str_replace($url, $new_url);
        }
    }
    return $img;
};
```

## on_extract_field($fieldname, $data, $page)

当一个field的内容被抽取到后进行的回调, 在此回调中可以对网页中抽取的内容作进一步处理

> @param $fieldname 当前field的name. 注意: 子field的name会带着父field的name, 通过.连接.
> @param $data 当前field抽取到的数据. 如果该field是repeated, data为数组类型, 否则是String
> @param $page 当前正在爬取的网页页面的对象
> @return 返回处理后的数据, 注意数据类型需要跟传进来的 `$data` 类型匹配
>
> > @param $page['url'] 当前网页的URL
> > @param $page['raw'] 当前网页的内容
> > @param $page['request'] 当前网页的请求对象

举个栗子:
比如爬取知乎用户的性别信息,相关网页源码如下:

那么可以这样写:

```
$configs = array(
    // configs的其他成员
    'fields' => array(
        array(
            'name' => "gender",
            'selector' => "//span[contains(@class, 'gender')]/i/
@class",
        ),
        ...
    )
);

$spider->on_extract_field = function($fieldname, $data, $page)
{
    if ($fieldname == 'gender')
    {
        // data中包含"icon-profile-male"，说明当前知乎用户是男性
        if (strpos($data, "icon-profile-male") !== false)
        {
            return "男";
        }
        // data中包含"icon-profile-female"，说明当前知乎用户是女性
        elseif (strpos($data, "icon-profile-female") !== false)
        {
            return "女";
        }
        else
        {
            return "未知";
        }
    }
    return $data;
};
```

## on_extract_page($page, $data)

在一个网页的所有field抽取完成之后, 可能需要对field进一步处理, 以发布到自己的网站

> @param $page 当前正在爬取的网页页面的对象
> @param $data 当前网页抽取出来的所有field的数据
> @return 返回处理后的数据, 注意数据类型需要跟传进来的 `$data` 类型匹配
>
> > @param $page['url'] 当前网页的URL
> > @param $page['raw'] 当前网页的内容
> > @param $page['request'] 当前网页的请求对象

举个栗子:
比如从某网页中得到time和title两个field抽取项, 现在希望把time的值添加中括号后拼凑到title中，处理过程如下：

```
$spider->on_extract_page = function($page, $data)
{
    $title = "[{$data['time']}]" . $data['title'];
    $data['title'] = $title;
    return $data;
};
```

# 爬虫进阶开发——之技巧篇

本节是开发爬虫模板时需要了解的技巧。包括，在爬取网站过程中经常遇到的问题，回调函数和内置函数的使用技巧等。

# 如何实现模拟登录？

> 通过模拟登录, 可以解决登录后才能爬取某些网站数据的问题. 接下来给你介绍模拟登录的实现.

通过发送HTTP请求来实现模拟登录.

举个栗子:

```
// 登录请求url
$login_url = "http://www.waduanzi.com/login?url=http%3A%2F%2Fwww
.waduanzi.com%2F";
// 提交的参数
$params = array(
    "LoginForm[returnUrl]" => "http%3A%2F%2Fwww.waduanzi.com%2F"
,
    "LoginForm[username]" => "13712899314",
    "LoginForm[password]" => "854230",
    "yt0" => "登录",
);
// 发送登录请求
requests::post($login_url, $params);
// 登录成功后本框架会把Cookie保存到www.waduanzi.com域名下，我们可以看看
是否是已经收集到Cookie了
$cookies = requests::get_cookies("www.waduanzi.com");
print_r($cookies);  // 可以看到已经输出Cookie数组结构

// requests对象自动收集Cookie，访问这个域名下的URL会自动带上
// 接下来我们来访问一个需要登录后才能看到的页面
$url = "http://www.waduanzi.com/member";
$html = requests::get($url);
echo $html;     // 可以看到登录后的页面，非常棒
```

## 如何获得提交参数？

登录需要登录验证信息，下面我们来看看如何获得一个网站所需要的登录信息
还是以挖段子(www.waduanzi.com)为例，看看如何获得下面的信息

**1**、打开挖段子网站点击登录按钮进入登陆页：

```
http://www.waduanzi.com/login?url=http%3A%2F%2Fwww.waduanzi.com%2F
```

**2**、鼠标点击右键 **->** 检查 从而打开**Chrome**浏览器的开发者工具


选择**Network**选项卡，勾选**Preserve log**选项


**3**、填写登陆信息点击登录按钮，得到登录验证**URL**

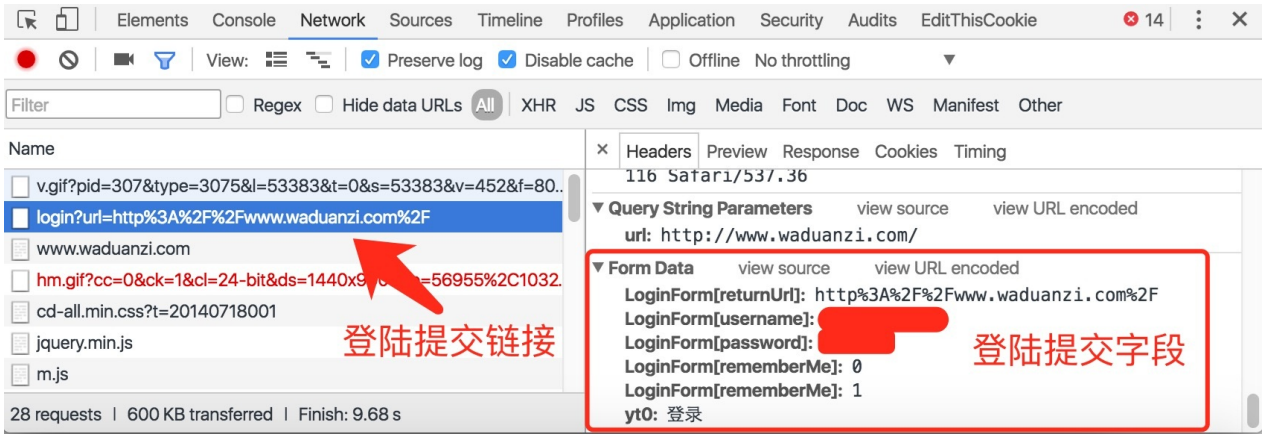


**4**、上面的登录提交字段填入框架代码

```
$params => array(
    "LoginForm[returnUrl]" => "http%3A%2F%2Fwww.waduanzi.com%2F"
,
    "LoginForm[username]" => "用户名",
    "LoginForm[password]" => "密码",
    "yt0" => "登录",
)
```

大功告成**^_^**

# file_get_contents 设置代理抓取页面

## 普通页面获取

```
$url = "http://www.epooll.com/archives/806/";
$contents = file_get_contents($url);
preg_match_all("/<h1>(.*?)</h1>/is", $content, $matchs);
print_r($matchs[0]);
```

## 设置代理IP去采集数据

```
$context = array(
    'http' => array(
        'proxy' => 'tcp://192.168.0.2:3128',  //这里设置你要使用的代理ip及端口号
        'request_fulluri' => true,
    ),
);
$context = stream_context_create($context);
$html = file_get_contents("http://www.epooll.com/archives/806/",
 false, $context);
echo $html;
```

## 设置需要验证的代理IP去采集数据

```
$auth = base64_encode('USER:PASS');   //LOGIN:PASSWORD 这里是代理服务器的账户名及密码
$context = array(
    'http' => array(
        'proxy' => 'tcp://192.168.0.2:3128',  //这里设置你要使用的代理ip及端口号
        'request_fulluri' => true,
        'header' => "Proxy-Authorization: Basic $auth",
    ),
);
$context = stream_context_create($context);
$html = file_get_contents("http://www.epooll.com/archives/806/",
 false, $context);
echo $html;
```

# 如果内容页有分页，该如何爬取到完整数据？

> 如果要爬取的某个内容页中有多个分页，该如何爬取这个内容页的完整数据呢？这里就无法使用 `on_list_page` 回调函数了，而需要使用 `field` 中的 `attached_url` 来请求其他分页的数据。

举个栗子:
爬取某网站文章时，发现有些文章有多个内容页面，处理过程如下：

```
$configs = array(
    // configs 的其他成员
    ...
    'fields' => array(
        array(
            'name' => "contents",
            'selector' => "//div[@id='pages']//a//@href",
            'repeated' => true,
            'children' => array(
                array(
                    // 抽取出其他分页的url待用
                    'name' => 'content_page_url',
                    'selector' => "//text()"
                ),
                array(
                    // 抽取其他分页的内容
                    'name' => 'page_content',
                    // 发送 attached_url 请求获取其他的分页数据
                    // attached_url 使用了上面抓取的 content_page_u
rl
                    'source_type' => 'attached_url',
                    'attached_url' => 'content_page_url',
                    'selector' => "//*[@id='big-pic']"
                ),
            ),
        ),
    ),
);
```

在爬取到所有的分页数据之后，可以在 `on_extract_page` 回调函数中将这些数据组合成完整的数据

```
$spider->on_extract_field = function($fieldname, $data, $page)
{
    if ($fieldname == 'contents')
    {
        if (!empty($data))
        {
            $contents = $data;
            $data = "";
            foreach ($contents as $content)
            {
                $data .= $content['page_content'];
            }
        }
    }
    return $data;
};
```

# 如何快速请求页面测试爬虫

在运行爬虫框架前，我们可能需要做很多准备工作，比如：登录验证测试、内容提取规则测试，这个时候我们就可以把phpspider框架当做类库来使用，即不启用 `start()方法` 。

## 内容提取测试

比如我们来提取epooll这个站点的文章标题

```
$spider = new phpspider();
$url = "http://www.epooll.com/archives/806/";
$html = $spider->request_url($url);

$fieldname = "标题";
$selector = "//div[contains(@class,'page-header')]//h1/a";

$result = $spider->get_fields_xpath($html, $selector, $fieldname
);
print_r($result);
```

# 多任务爬虫

天下爬虫，唯快不破，配合多进程使用，phpspider可以快到你怕，下面我们来看看如何实现一个多任爬虫.

```
$configs = array(
    'name' => '糗事百科',
    'tasknum' => 4,                 // 爬虫任务数
    'save_running_state' => true,  // 保存运行状态
    ...
);
$spider = new phpspider($configs);
$spider->start();
```

# Swoole下的多任务爬虫

敬请期待 ^_^

# Workerman下的多任务爬虫

敬请期待 ^_^

# 如何实现爬虫集群负载

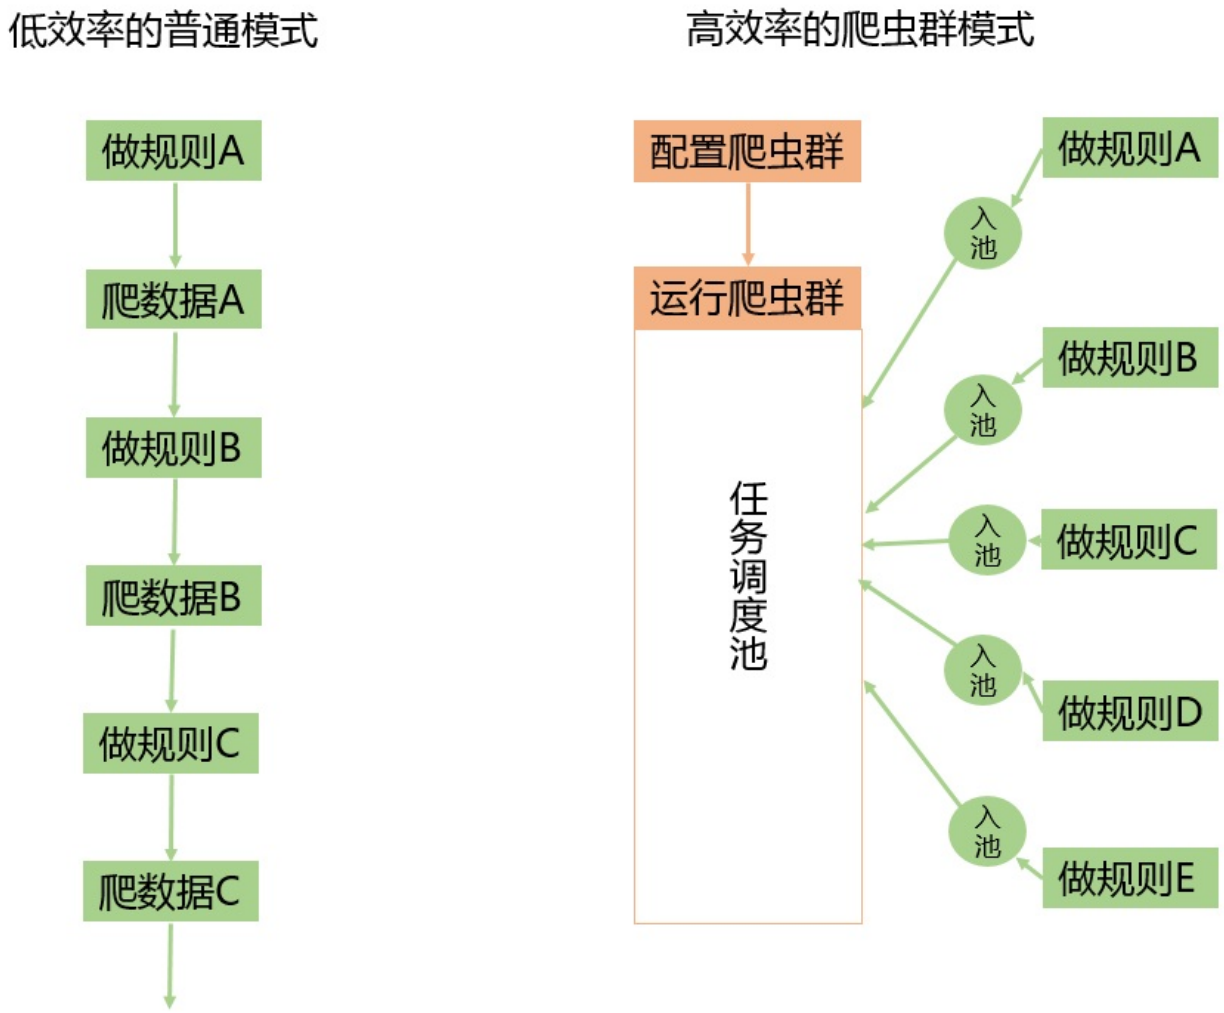


思路如上，功能敬请期待^_^